

OR4D-NCM811 Clean-Peak ACOM Benchmark

v3 构建、坐标审计与实验报告

Benchmark 概览

数据集标识: OR4D-NCM811-CleanPeak-acom-v3。公开输入为每个样本的变长理想运动学衍射峰集合 {qx, qy, intensity}, 隐藏标准答案为 3x3 orientation_matrix_sample_to_crystal。正式 headline 指标只在 1024 个 headline_core 样本上计算; 17 个 legacy_smoke 和 40 个 acom_grid_probe 始终单独报告。Canonical ACOM 使用 2°区轴步长与 2°面内步长, 并与 4°、3°配置进行受控扫描。

目录

1. 摘要	4
1.1. v2 到 v3 的主要变化	4
2. Benchmark 任务定义	5
2.1. 固定参考结构	5
2.2. 公开输入	5
2.3. 隐藏标准答案	6
2.4. 实空间、晶体倒空间与探测器坐标	9
2.5. Baseline 输入输出契约	10
3. 完整取向与手工控制参数	10
3.1. Zone axis (区轴)	10
3.2. x reference (面内参考方向)	10
3.3. In-plane rotation (面内旋转)	11
4. v3 取向采样设计	11
4.1. 三层数据集	11
4.2. Legacy smoke: 17 个回归样本	11
4.3. Headline core: 1024 个 ACOM 独立取向	11
4.3.1. 第一步: 生成三维 Sobol 点	12
4.3.2. 第二步: Shoemake 映射到单位四元数	12
4.3.3. 第三步: 处理四元数的二对一表示	13
4.3.4. 第四步: 单位四元数转换为旋转矩阵	14
4.3.5. 第五步: 生成全部 1024 个隐藏取向	15
4.3.6. 取向均匀性的准确含义	15
4.3.7. 与 ACOM Orientation Plan 的独立性	16
4.3.8. v2 到 v3 的确定性扩展	16
4.4. ACOM grid probes: 40 个诊断样本	16
5. Clean-Peak 数据生成	17
5.1. 固定模拟参数	17
5.2. 峰过滤与归一化	17
6. 程序依赖库与 py4DSTEM 关键接口	18
6.1. 程序依赖关系概览	18
6.2. py4DSTEM 在本项目中的作用	20

6.3.	py4DSTEM 的四个核心对象	20
6.4.	关键函数一：从 pymatgen 建立 Crystal	21
6.5.	关键函数二：设置电子衍射条件	22
6.6.	关键函数三：计算结构因子	22
6.7.	关键函数四：生成 Clean 衍射峰	23
6.8.	py4DSTEM 输出峰的后处理	24
6.9.	关键函数五：构造 ACOM 输入 PointList	25
6.10.	关键函数六：建立 Orientation Plan	25
6.11.	关键函数七：匹配单个衍射样本	27
6.12.	Orientation 返回字段	28
6.13.	py4DSTEM 完整输入、过程与输出	29
6.14.	pymatgen：晶体结构与对称性	30
6.15.	NumPy：矩阵和峰数组计算	31
6.16.	SciPy：采样、最近邻和一对一匹配	31
6.16.1.	Sobol 低差异采样	32
6.16.2.	ACOM Plan 最近邻审计	32
6.16.3.	探测器峰的一对一匹配	32
6.17.	h5py：变长峰集合存储	32
6.18.	PyYAML：统一配置管理	32
6.19.	Matplotlib：结果可视化	33
6.20.	Dynamical 轨道使用的库	33
6.21.	py4DSTEM 与项目自定义代码	33
7.	ACOM Baseline	34
7.1.	Canonical Orientation Plan 参数	34
7.2.	ACOM 匹配流程	35
7.3.	4° / 3° / 2°角分辨率扫描	35
8.	评价协议	35
8.1.	Proper crystal point-group rotations	35
8.2.	单个旋转矩阵的角度	35
8.3.	Strict misorientation	36
8.4.	Friedel-equivalent misorientation	36
8.5.	数据集汇总指标	36
9.	v3 实验结果	36
9.1.	Headline core 总体结果	36
9.2.	按 sample role 汇总	37
9.3.	Grid probe 按区轴分解	37
9.4.	按最近区轴节点距离分箱	38
9.5.	按公开峰数量分箱	38
9.6.	运行性能	38
10.	坐标与峰级审计	38
10.1.	全局坐标一致性	38
10.2.	代表样本	39
10.3.	Headline 最严重错误样本	39
11.	可视化结果	40
11.1.	误差分布	40

11.2. 区轴网格距离与误差	40
11.3. 输入峰与预测峰叠加	41
12. 可复现性	41
12.1. 软件与系统	41
12.2. SHA256	42
12.3. 工程目录	42
12.4. 完整运行	42
13. 结论	43
14. 附录：术语	43

1. 摘要

本 Benchmark 评测：在已知 NCM811 参考晶体结构的条件下，算法能否仅根据一组理想电子衍射峰的位置与相对强度，恢复晶体的完整三维取向。

Benchmark 数据链

```
固定 NCM811 CIF
+ 隐藏完整取向 R_gt
→ py4DSTEM 运动学衍射模拟
→ 公开峰集合 {qx, qy, intensity}
→ ACOM Orientation Plan 稀疏相关匹配
→ 预测完整取向 R_pred
→ proper crystal symmetry + Friedel 等价评价
```

v3 共包含 1081 个样本：

- legacy_smoke: 17 个，用于回归、坐标约定和 mirror/Friedel 检查；
- headline_core: 1024 个，由固定 seed 的 scrambled Sobol(3) 经 Shoemake 映射到 SO(3)，用于正式主指标；
- acom_grid_probe: 40 个，由 5 个低指数区轴与 8 个 2° 网格内偏移组成，只用于诊断面内亚网格行为。

Canonical 2° ACOM 在 1024 个 headline_core 上的主结果为：

指标	Friedel 主指标	Strict 指标
样本数	1024	1024
平均取向差	1.625°	5.703°
中位取向差	0.977°	0.978°
P90	1.922°	1.979°
P95	3.525°	59.748°
最大误差	89.850°	96.620°
Acc@1°	52.1%	52.0%
Acc@2°	90.5%	90.0%
Acc@5°	96.7%	93.1%

Strict/Friedel 分歧率为 6.45%。主指标中有 34/1024 个样本误差大于 5°，12/1024 个样本误差大于 10°。

本结果属于 matched-model self-consistency (同模型自治) 测试：Clean 输入和 ACOM 模板使用同一 CIF 与同一 py4DSTEM 运动学模型。它不代表真实实验数据、独立模拟器或动力学衍射上的泛化能力。

1.1. v2 到 v3 的主要变化

项目	v2	v3
总样本数	569	1081
Headline core	512	1024；前 512 个确定性保持
Canonical ACOM	4° / 4°	2° / 2°

项目	v2	v3
ACOM 搜索种子 (含 mirror)	49,680	389,160
k_max	2.0 Å ⁻¹	1.5 Å ⁻¹ ; 生成与模板统一
角分辨率扫描	无	4°、3°、2°受控扫描
坐标审计	基本矩阵闭环	逐样本逐反射 HKL→g→q 链路
自动化测试	有限	采样、坐标链路、提交契约测试


2. Benchmark 任务定义

2.1. 固定参考结构

固定结构文件:

```
data/structure/NCM811_113035.cif
```

材料名义组成为:



主要晶体学信息:

项目	当前值
Space group (空间群)	R -3 m H
空间群编号	166
晶格常数	$a = b = 2.87834 \text{ Å}, c = 14.2622 \text{ Å}$
晶格角	$\alpha = \beta = 90^\circ, \gamma = 120^\circ$
3b 位点	Li 0.9926, Ni 0.0074
3a 位点	Ni 0.8, Mn 0.1, Co 0.1
O 位点	O 1.0

Clean 轨道使用 Average-occupancy structure (平均占位结构)。CIF 中的 Ni/Mn/Co 混合占位与 Li/Ni 混排通过部分占位率参与平均结构因子计算。

2.2. 公开输入

每个样本公开一个变长峰集合:

$$X_i = ((q_{x,j}, q_{y,j}, I_j))_{j=1}^{M_i}$$

其中:

- M_i : 第 i 个样本中的峰数量;
- q_x, q_y : 探测器平面倒空间坐标, 单位 Å⁻¹;
- I : 单样本最大值归一化后的理论峰强度。

公开文件:

```
public/clean_peaks.h5
```

HDF5 结构:

```
/sample_id
/peaks/qx
/peaks/qy
/peaks/intensity
/peaks/offsets
```

offsets 用于从拼接数组中恢复每个样本的变长峰列表。v3 全部 1081 个样本峰数范围为 12–80，平均 21.56；headline_core 峰数范围为 12–52，平均 20.52。

2.3. 隐藏标准答案

每个样本的隐藏答案为：

```
orientation_matrix_sample_to_crystal
```

坐标约定：

$$\mathbf{v}_{\text{crystal}} = R_{\text{sample} \rightarrow \text{crystal}} \mathbf{v}_{\text{sample}}$$

矩阵三列描述的是 **样品坐标系的三根基轴**，而不是衍射峰的 qx、qy、qz 数值。设

$$R_{\text{sample} \rightarrow \text{crystal}} = (e_x^c, e_y^c, e_z^c)$$

则：

取向矩阵 $R_{\text{sample} \rightarrow \text{crystal}}$ (后文简称 R) 三列的物理含义

第 1 列 e_x^c ：

sample x 基轴在晶体笛卡尔坐标系中的坐标。

第 2 列 e_y^c ：

sample y 基轴在晶体笛卡尔坐标系中的坐标。

第 3 列 e_z^c ：

sample z 基轴在晶体笛卡尔坐标系中的坐标。

本项目中，sample z 与电子束方向一致。

这里的 sample x 、 y 、 z 是样品坐标系的空间方向。

qx、qy、qz 是一个倒易矢量在样品坐标系中的坐标分量。两者通过坐标投影建立联系。

设某个晶体反射的 Miller 指数为 (h, k, l) 。

Miller 指数只是三个无量纲整数，它们表示该反射由多少个倒易晶格基矢组合而成，本身不是笛卡尔倒空间坐标，也不能直接作为 qx、qy、qz。

CIF 文件首先给出实空间晶格基矢：

$$\mathbf{a}, \mathbf{b}, \mathbf{c}$$

由实空间晶格可以得到倒易晶格基矢：

$$\mathbf{a}^*, \mathbf{b}^*, \mathbf{c}^*$$

它们的单位为 $\text{\AA}^{-1}$ 。于是，Miller 指数 (h, k, l) 对应的 晶体笛卡尔倒易矢量为：

$$\mathbf{g}_{\text{crystal}} = h\mathbf{a}^* + k\mathbf{b}^* + l\mathbf{c}^*$$

这里的下标 crystal 只表示：该倒易矢量当前使用晶体笛卡尔 坐标系表示，并不表示晶体又经过了一次变换。

由于当前隐藏取向矩阵定义为：

$$\mathbf{v}_{\text{crystal}} = R_{\text{sample} \rightarrow \text{crystal}} \mathbf{v}_{\text{sample}}$$

所以，要把已经位于晶体坐标系中的倒易矢量转换到样品坐标系， 需要使用逆变换。合法旋转矩阵满足 $R^{-1} = R^T$ ，因此：

$$\mathbf{g}_{\text{sample}} = R_{\text{sample} \rightarrow \text{crystal}}^T \mathbf{g}_{\text{crystal}}$$

程序中 $\mathbf{g}_{\text{crystal}}$ 的获得方式

程序使用 pymatgen 从 CIF 读取晶格结构：

```
structure = Structure.from_file(  
    cif_path(config)  
)
```

随后读取晶体学倒易晶格矩阵：

```
reciprocal_matrix = np.asarray(  
    structure.lattice  
        .reciprocal_lattice_crystallographic  
        .matrix,  
    dtype=float,  
)
```

这里使用的是 crystallographic reciprocal lattice， 单位为 $\text{\AA}^{-1}$ ，并且不包含额外的 2π 因子。

对于 py4DSTEM 给出的某个诊断反射 (h, k, l) ， 程序在 src/coordinate_trace.py 中计算：

```
g_crystal = (  
    np.asarray(hkl, dtype=float)  
    @ reciprocal_matrix  
)
```

这正对应：

```
g_crystal = h a* + k b* + l c*
```

随后程序计算：

```
g_sample = (  
    orientation_sample_to_crystal.T  
    @ g_crystal  
)
```

得到倒易矢量在样品坐标系中的三个分量。

在正常的 Clean-Peak 数据生成过程中，`py4DSTEM.generate_diffraction_pattern` 会在内部完成倒易反射、取向变换和探测器投影，并直接输出 `qx`、`qy` 和 `intensity`。

`py4DSTEM` 同时在诊断字段中提供对应反射的 `h`、`k`、`l`。项目将这些字段写入：

```
diagnostics/clean_reflections.h5
```

但不会写入公开输入。

`scripts/10_trace_clean_coordinates.py` 再根据诊断用的 (h, k, l) 显式重建 g_{crystal} 和 g_{sample} ，用于验证程序输出的 `qx`、`qy` 是否与坐标约定一致。

展开后：

$$g_{\text{sample}} = \begin{pmatrix} q_x \\ q_y \\ q_z \end{pmatrix}$$

也就是：

$$q_x = (e_x^c)^T g_{\text{crystal}}$$

$$q_y = (e_y^c)^T g_{\text{crystal}}$$

$$q_z = (e_z^c)^T g_{\text{crystal}}$$

因此，更准确的对应关系是：

样品基轴与倒空间分量的关系

sample x :

是样品坐标系的一根空间基轴

qx :

是倒易矢量 g 在 sample x 对应方向上的坐标分量

sample y :

是样品坐标系的一根空间基轴

qy :

是倒易矢量 g 在 sample y 对应方向上的坐标分量

sample z :

是样品坐标系中沿电子束方向的基轴

qz :

是倒易矢量 g 在电子束方向上的坐标分量

不能将 sample x 与 `qx`、sample y 与 `qy` 直接等同。

前者是坐标基轴的方向，属于样品坐标框架；后者是倒易矢量沿相应方向的分量，属于倒空间坐标，单位为 $\text{\AA}^{-1}$ 。

它们之间的关系类似于： x 轴规定测量方向，而某个向量的 x 分量表示该向量在这根轴上的投影。

探测器平面垂直于电子束，即垂直于 sample z 轴。因此衍射峰公开的二维位置是倒易矢量在探测器平面中的横向分量：

$$q_{\text{detector}} = q_x e_x + q_y e_y$$

公开数据只保存：

```
qx
qy
intensity
```

其中 q_x 和 q_y 决定衍射峰在二维探测器平面中的位置。

q_z 是倒易矢量沿电子束方向的分量，与激发误差和 Ewald 球条件有关，但不作为当前 Clean-Peak 数据中的二维峰坐标公开。

这里使用 $g_{\text{sample}} = R^T g_{\text{crystal}}$ 的前提是： g_{crystal} 已经表示为晶体笛卡尔坐标中的倒易矢量，而不是直接把 Miller 指数 (h, k, l) 当作笛卡尔坐标。

程序中的完整过程是：

```
Miller 指数 (h, k, l)
-> 通过倒易晶格矩阵得到 g_crystal
-> 使用 R^T 得到 g_sample
-> 读取 qx、qy、qz 分量
```

合法矩阵满足：

$$R^T R = I, \quad \det(R) = 1$$

隐藏标准答案文件：

```
private/clean_ground_truth.jsonl
```

2.4. 实空间、晶体倒空间与探测器坐标

为避免把实空间轴与倒空间坐标混为一谈，v3 增加了逐反射坐标追踪。

直接晶格矩阵 A 的三行分别为实空间基矢 a, b, c 。晶体学倒易基矩阵 B 的三行分别为 a^*, b^*, c^* ，单位为 $\text{\AA}^{-1}$ ，且不包含额外的 2π 因子。

$$B = \begin{pmatrix} a_x^* & a_y^* & a_z^* \\ b_x^* & b_y^* & b_z^* \\ c_x^* & c_y^* & c_z^* \end{pmatrix}$$

将 Miller 指数写成列向量：

$$\mathbf{h} = \begin{pmatrix} h \\ k \\ l \end{pmatrix}$$

则反射 (h, k, l) 在晶体笛卡尔坐标系中的倒易矢量为：

$$g_{\text{crystal}} = B^T \mathbf{h} = h a^* + k b^* + l c^*$$

取向矩阵 $R_{\text{sample} \rightarrow \text{crystal}}$ 满足：

$$\mathbf{v}_{\text{crystal}} = R_{\text{sample} \rightarrow \text{crystal}} \mathbf{v}_{\text{sample}}$$

因此，将倒易矢量从晶体坐标系转换到样品坐标系时：

$$\mathbf{g}_{\text{sample}} = R_{\text{sample} \rightarrow \text{crystal}}^T \mathbf{g}_{\text{crystal}}$$

样品坐标中的三个倒易分量为：

$$\mathbf{g}_{\text{sample}} = \begin{pmatrix} q_x \\ q_y \\ q_z \end{pmatrix}$$

其中 q_x 和 q_y 是探测器平面中的公开峰坐标， q_z 是沿电子束方向的分量，不作为当前公开峰表的二维坐标。因此 q_x, q_y 不是实空间 x, y 本身，而是晶体倒易矢量在 sample x、sample y 基轴上的坐标分量；公开输入只保留垂直于电子束的探测器平面分量 q_x, q_y 。

逐反射坐标链

```
(h, k, l)
→ g_crystal = [h, k, l] @ B
→ g_sample = R_sample_to_crystal.T @ g_crystal
→ qx = g_sample[0]
→ qy = g_sample[1]
→ qz = g_sample[2] (沿电子束, 不公开)
```

v3 坐标追踪的全局最大标准恒等式残差为 $8.074 \times 10^{-8} \text{ \AA}^{-1}$ 。

2.5. Baseline 输入输出契约

统一接口

```
INPUT
  sample_id
  peaks = {qx, qy, intensity}

OUTPUT
  sample_id
  orientation_matrix_sample_to_crystal
```

ACOM 通过 py4DSTEM PointList 读取 qx、qy、intensity。Benchmark 不要求提交区轴、欧拉角、面内旋转角、normal/mirror 分支或相关分数。

3. 完整取向与手工控制参数

3.1. Zone axis (区轴)

zone_axis_uvw = [u, v, w] 用于确定电子束相对晶体的方向：

$$\mathbf{z} = \text{normalize}(u\mathbf{a} + v\mathbf{b} + w\mathbf{c})$$

它成为取向矩阵第三列，提供完整三维取向的两个角自由度。

3.2. x reference (面内参考方向)

x_reference_uvw 是晶体直接晶格中的方向。脚本将其投影到垂直于区轴的平面：

$$\mathbf{x}_0 = \text{normalize}(\mathbf{x}_{\text{ref}} - (\mathbf{x}_{\text{ref}} \cdot \mathbf{z})\mathbf{z})$$

$$\mathbf{y}_0 = \text{normalize}(\mathbf{z} \times \mathbf{x}_0)$$

它只定义面内旋转为 0° 时的 sample x 方向。

3.3. In-plane rotation (面内旋转)

保持区轴不变，绕 sample z 轴旋转 φ ：

$$\mathbf{x} = \cos(\varphi)\mathbf{x}_0 + \sin(\varphi)\mathbf{y}_0$$

$$\mathbf{y} = -\sin(\varphi)\mathbf{x}_0 + \cos(\varphi)\mathbf{y}_0$$

最终：

$$R_{\text{sample} \rightarrow \text{crystal}} = [\mathbf{x}, \mathbf{y}, \mathbf{z}]$$

这三个参数只用于构造少量可人工检查的控制取向。正式 headline_core 直接由 SO(3) 四元数生成，权威真值始终是完整 3×3 取向矩阵。

4. v3 取向采样设计

4.1. 三层数据集

sample_role	数量	生成方式	用途
legacy_smoke	17	9 个手工控制 + 8 个确定性 SO(3)	回归与约定检查
headline_core	1024	scrambled Sobol(3) + Shoemake SO(3)	唯一正式主测试集
acom_grid_probe	40	5 个区轴 × 8 个 2° 网格内偏移	ACOM 亚网格诊断

总样本数：

$$17 + 1024 + 40 = 1081$$

4.2. Legacy smoke: 17 个回归样本

前 9 个样本保留 v1 手工控制：5 个低指数区轴与 4 个非零面内旋转；后 8 个保留 v1 的确定性低差异 SO(3) 样本。它们不进入 headline 指标。

ID	Zone axis	x reference	In-plane
ori_000	[001]	[100]	0°
ori_001	[100]	[001]	0°
ori_002	[110]	[001]	0°
ori_003	[101]	[010]	0°
ori_004	[102]	[010]	0°
ori_005	[001]	[100]	6.1°
ori_006	[100]	[001]	14.2°
ori_007	[110]	[001]	22.3°
ori_008	[101]	[010]	30.4°

4.3. Headline core: 1024 个 ACOM 独立取向

Headline core 用于评价算法在一般三维取向上的表现。

这里所说的“生成 $so(3)$ 取向”，不是直接随机生成九个矩阵元素，也不是在若干低指数区轴中进行枚举，而是采用：

```
三维 scrambled Sobol 低差异序列
→ Shoemake 单位四元数映射
→ 单位四元数转 proper rotation matrix
→ 得到  $SO(3)$  中的取向矩阵
```

其中， $so(3)$ 表示全部三维 proper rotation 的集合。合法矩阵满足：

$$R^T R = I, \quad \det(R) = 1$$

它们只表示三维旋转，不包含镜像、反演或缩放。

4.3.1. 第一步：生成三维 Sobol 点

程序首先使用 SciPy 的三维 Sobol 低差异序列：

```
points = qmc.Sobol(
    d=3,
    scramble=True,
    seed=20260728,
).random_base2(10)
```

random_base2(10) 一次生成：

$$2^{10} = 1024$$

个三维点。每个点写为：

$$\mathbf{u} = (u_1, u_2, u_3), \quad u_1, u_2, u_3 \in [0, 1)$$

Sobol 序列与普通独立随机采样不同。

普通随机采样可能在局部出现明显聚集和空洞；Sobol 序列属于 低差异序列，目的是使有限数量的点更均匀地覆盖单位立方体 $[0, 1)^3$ 。

这里设置：

```
scramble = true
seed = 20260728
```

表示对 Sobol 数字序列进行固定 seed 的随机化。它仍然具有确定性：只要 SciPy 版本、参数和 seed 不变，每次运行得到的 1024 个点完全相同。

Sobol 点本身只是位于三维单位立方体中的参数点，还不是旋转矩阵，也不是取向角。

程序还需要通过 Shoemake 映射，将每个三维点转换成单位四元数。

4.3.2. 第二步：Shoemake 映射到单位四元数

对于一个 Sobol 点：

$$(u_1, u_2, u_3) \in [0, 1)^3$$

程序使用 Shoemake 映射计算：

$$x = \sqrt{1 - u_1} \sin(2\pi u_2)$$
$$y = \sqrt{1 - u_1} \cos(2\pi u_2)$$

$$z = \sqrt{u_1} \sin(2\pi u_3)$$

$$w = \sqrt{u_1} \cos(2\pi u_3)$$

然后按照程序使用的 wxyz 顺序组成四元数：

$$\mathbf{q} = (w, x, y, z)$$

由三角恒等式可得：

$$x^2 + y^2 + z^2 + w^2 = 1$$

因此， $\mathbf{q}$ 一定位于四维单位球面 S^3 上，是一个单位四元数。

Shoemake 映射中三个输入参数的作用

u_1 决定四元数两组分量之间的平方长度分配：

$$x^2 + y^2 = 1 - u_1$$

$$z^2 + w^2 = u_1$$

u_2 决定 (x, y) 平面中的相位角。

u_3 决定 (z, w) 平面中的相位角。

这种构造不是把四个四元数分量分别随机生成后再归一化，而是直接按照适合旋转群的分布构造单位四元数。

当 (u_1, u_2, u_3) 在单位立方体中均匀分布时，Shoemake 映射在 S^3 上产生均匀单位四元数；通过单位四元数与三维旋转的对应关系，可得到相对于 Haar 测度均匀的 $so(3)$ 旋转分布。

本项目输入的不是独立伪随机点，而是 scrambled Sobol 点。因此，有限的 1024 个取向更准确地说是：

> 通过 Shoemake 映射得到的、对 $so(3)$ 进行低差异近似覆盖的取向集合。

它不是规则欧拉角网格，也不是 ACOM Orientation Plan 中的离散节点。

4.3.3. 第三步：处理四元数的二对一表示

单位四元数存在：

$$\mathbf{q}$$

与

$$-\mathbf{q}$$

表示同一个三维旋转的性质。

因此，单位四元数球面 S^3 对 $so(3)$ 是二对一表示：每个旋转同时对应一对互为相反数的四元数。

为了让存储结果具有唯一、稳定的符号约定，程序执行：

```
if q_wxyz[0] < 0:
    q_wxyz = -q_wxyz
```

也就是优先令四元数的标量部分：

$$w \geq 0$$

这一操作只改变四元数的符号，不改变它表示的旋转。

程序最后再次归一化：

```
q_wxyz = q_wxyz / np.linalg.norm(q_wxyz)
```

以消除浮点运算造成的极小单位长度误差。

4.3.4. 第四步：单位四元数转换为旋转矩阵

程序将单位四元数：

$$\mathbf{q} = (w, x, y, z)$$

通过标准四元数旋转公式转换成 3×3 矩阵：

$$R = R(\mathbf{q})$$

实现函数为：

```
quaternion_wxyz_to_matrix(  
    quaternion_wxyz  
)
```

转换结果使用本 Benchmark 的坐标约定：

$$\mathbf{v}_{\text{crystal}} = R_{\text{sample} \rightarrow \text{crystal}} \mathbf{v}_{\text{sample}}$$

因此，得到的矩阵不是一个没有方向定义的抽象旋转，而是：

```
orientation_matrix_sample_to_crystal
```

矩阵三列依次表示 sample x 、 y 、 z 三根基轴在 crystal 笛卡尔坐标系中的方向。

程序还使用 nearest_rotation 消除浮点数造成的极小非正交误差，并验证：

$$R^T R \approx I$$

$$\det(R) \approx 1$$

所以最终保存的每个 R_{gt} 都是 proper rotation，属于 $\text{so}(3)$ 。

单个 Headline 取向的完整生成过程

```
一个 Sobol 点  
(u1, u2, u3)  
    |  
    v  
Shoemake 映射  
    |  
    v  
单位四元数  
q = (w, x, y, z)  
    |  
    v  
处理 q 与 -q 的等价符号  
    |  
    v  
四元数转旋转矩阵  
    |  
    v
```

数值投影和合法性检查

|

v

$R_{gt} \in SO(3)$

4.3.5. 第五步：生成全部 1024 个隐藏取向

Headline 的完整生成链为：

Sobol-Shoemake $so(3)$ 主测试集

固定 seed 的 scrambled Sobol(3)

- random_base2(10) 生成 1024 个三维点
- 每个点经 Shoemake 映射得到单位四元数
- 统一为 $w \geq 0$ 的四元数符号约定
- 单位四元数转换为 3×3 proper rotation
- 验证 $R^T R = I$ 且 $\det(R) = +1$
- 审计 crystal symmetry / Friedel 等价重复
- 得到 1024 个隐藏 R_{gt}
- 使用每个 R_{gt} 模拟公开 Clean-Peak 峰集

程序中的核心调用关系为：

```
quaternions = sobol_so3_quaternions(  
    count=1024,  
    scramble=True,  
    seed=20260728,  
)  
  
for quaternion in quaternions:  
    matrix = quaternion_wxyz_to_matrix(  
        quaternion  
    )
```

固定参数：

参数	值
method	sobol_shoemake
count	1024
Sobol dimension	3
random_base2 exponent	10
scramble	true
seed	20260728
quaternion order	wxyz
duplicate tolerance	10^{-6}

4.3.6. 取向均匀性的准确含义

“均匀覆盖 $so(3)$ ”不表示任意有限的 1024 个点之间角距离完全相同。

s0(3) 不能像普通矩形网格一样, 被有限个点划分为处处等间距的规则网格。本项目采用 Sobol-Shoemake 方法的目标是:

- 避免普通随机采样产生明显聚集和大范围空洞;
- 避免只测试少量人工选择的低指数区轴;
- 避免欧拉角均匀采样造成的取向分布偏置;
- 使有限样本对 s0(3) 的 Haar 测度形成较好的低差异近似;
- 保证固定 seed 下结果完全可复现。

因此, Headline core 应描述为:

> 固定 seed 的 scrambled Sobol 低差异点, 经 Shoemake 单位四元数 > 映射得到的确定性、近似均匀 s0(3) 取向集合。

不应描述为“1024 个均匀欧拉角”, 也不应描述为“1024 个 ACOM 网格取向”。

4.3.7. 与 ACOM Orientation Plan 的独立性

Headline 取向生成过程不会读取:

- ACOM Orientation Plan;
- ACOM 区轴节点;
- ACOM 面内角节点;
- ACOM 相关分数;
- ACOM 预测矩阵;
- 最终预测误差。

因此, Headline 不是先从 ACOM 搜索网格中挑选取向, 也不会因为某个样本匹配失败而将其删除。

生成阶段只使用 NCM811 的 proper crystal symmetry 和 Benchmark 定义的 Friedel 等价关系, 对候选取向执行数值重复审计。

对于每个新取向, 程序计算它与先前取向之间的最小 Clean-equivalent misorientation。若距离不超过:

$$10^{-6}^{\circ}$$

程序会直接报告重复错误并终止生成, 而不是悄悄删除样本或重新选择一个对 ACOM 更有利的取向。

v3 的 1024 个 Headline 候选全部通过该审计。

4.3.8. v2 到 v3 的确定性扩展

Sobol 的 random_base2 数字网具有嵌套性质。

在 scramble、seed 和维数保持不变时:

```
v2 : random_base2(9)  → 512 个点
v3 : random_base2(10) → 1024 个点
```

v3 的前 512 个 Sobol 点与 v2 的 512 个点一致, 新增的是后续 512 个点。

因此, v3 是 v2 的确定性扩展, 而不是重新随机生成了一套与 v2 无关的 Headline 取向。

4.4. ACOM grid probes: 40 个诊断样本

Probe 显式依赖 canonical 2°面内网格, 因此不参与公平排名。

Probe axes	数量	每个区轴的面内偏移
[001] [100] [110] [101] [102]	5 × 8	0.125° 至 1.0°, 步长 0.125°

这些偏移覆盖一个 2° 网格单元从小偏移到半步边界。ACOM 会对面内相关峰做抛物线亚网格拟合，因此最近离散 seed 距离只是诊断量，不是误差下界。

5. Clean-Peak 数据生成

v3 Clean 生成链

```
CIF 平均占位结构
+ 取向矩阵 R_gt
+ 300 kV 电子束
→ py4DSTEM 运动学结构因子与反射
→ 输出 qx, qy, intensity, h, k, l
→ 删除中心束  $q < 0.03 \text{ \AA}^{-1}$ 
→ 保留  $q \leq 1.5 \text{ \AA}^{-1}$ 
→ 单样本最大值归一化
→ 公开 {qx, qy, intensity}
```

5.1. 固定模拟参数

参数	值	说明
accelerating_voltage_V	300000 V	300 kV 加速电压
k_max_Ainv	$1.5 \text{ \AA}^{-1}$	公开峰与 ACOM 模板统一
central_beam_exclusion_Ainv	$0.03 \text{ \AA}^{-1}$	中心束排除半径
sigma_excitation_error_Ainv	$0.02 \text{ \AA}^{-1}$	激发误差宽度
tol_excitation_error_mult	3.0	激发误差容差倍数
tol_structure_factor	10^{-4}	结构因子阈值
tol_intensity	10^{-4}	峰强度阈值
normalize_peak_intensity	max	单样本最大值归一化
conventional_standard_structure	False	保留 CIF 当前晶胞表示

v3 将生成器和 ACOM 模板统一为 $k_{\text{max}} = 1.5 \text{ \AA}^{-1}$ 。升级前的 $2.0 \text{ \AA}^{-1}$ 数据保存在备份中，不与 v3 指标混合。

5.2. 峰过滤与归一化

峰处理规则

1. 删除 NaN 与 $\pm\text{Inf}$
2. $q = \sqrt{q_x^2 + q_y^2}$
3. 删除 $q < 0.03 \text{ \AA}^{-1}$
4. 保留 $q \leq 1.5 \text{ \AA}^{-1}$
5. 保留 $\text{intensity} > 0$
6. $\text{intensity} /= \max(\text{intensity})$
7. 按 q 、 q_x 、 q_y 确定性排序

公开输入不含 HKL。 h, k, l 只写入诊断数据，用于追踪坐标链，不允许 Baseline 使用。

6. 程序依赖库与 py4DSTEM 关键接口

本项目基于 Python 3.11 构建。Clean-Peak v3 的核心工作由 py4DSTEM 0.14.18 完成，其他库分别负责晶体结构读取、数值计算、取向采样、文件存储、结果评价和可视化。

本项目安装的是带 ACOM 扩展的 py4DSTEM：

```
py4DSTEM[acom] == 0.14.18
```

本节中的库和函数说明对应本项目实际代码，而不是对这些库全部功能的完整介绍。

Clean-Peak 数据生成主要位于：

- scripts/02_generate_clean.py

ACOM Baseline 主要位于：

- scripts/07_run_acom_baseline.py

数据校验和坐标审计分别位于：

- scripts/04_validate_dataset.py
- scripts/10_trace_clean_coordinates.py

6.1. 程序依赖关系概览

从 CIF 到评价结果的库调用链

```
NCM811 CIF
| 晶体结构文件
| 包含晶格、原子位置、元素和占位率
v
pymatgen.Structure
| 读取并解析 CIF
| 建立统一的晶体结构对象
v
py4DSTEM Crystal
| 将晶体结构转换为 py4DSTEM
| 可用于电子衍射模拟和 ACOM 的对象
|
+--> setup_diffraction
| 设置电子束和衍射条件
|
+--> calculate_structure_factors
| 生成倒易晶格反射
| 计算各反射的结构因子和理论强度
|
+--> generate_diffraction_pattern
| 输入隐藏真实取向 R_gt
| 模拟该取向下的运动学衍射峰
|
| v
| PointList(qx, qy, intensity)
| 离散衍射峰集合
| qx、qy 为探测器平面倒空间坐标
| intensity 为理论相对强度
|
```

```

|      +--> h5py 写入公开峰数据
|      过滤中心束和非法峰
|      强度归一化后写入 HDF5
|
+--> orientation_plan
    根据晶体对称性和角步长
    预生成 ACOM 候选取向模板
    |
    v
    match_single_pattern
        将公开 PointList 转为极坐标表示
        与 Orientation Plan 逐一相关匹配
        选择相关分数最高的候选取向
        |
        v
        Orientation
            ACOM 返回的取向匹配结果对象
            |
            +--> matrix
            |      完整 3x3 预测取向矩阵
            |      Benchmark 中记为 R_pred
            |
            +--> corr
            |      最佳候选的相关分数
            |
            +--> inds
            |      最佳区轴节点和面内角索引
            |
            +--> mirror
            |      是否来自 ACOM mirror 分支
            |
            +--> angles
            |      ACOM 使用的取向角参数
            |
            v
            NumPy + pymatgen 对称性评价
                NumPy 处理矩阵和角度计算
                pymatgen 提供晶体对称操作
                比较 R_pred 与隐藏 R_gt
                输出 Strict 和 Friedel 误差

```

各库在当前 Clean-Peak 轨道中的主要分工如下。

- py4DSTEM: 运动学衍射模拟、Orientation Plan 建立和 ACOM 匹配。
- pymatgen: 读取 CIF、表示晶体结构和提取晶体点群操作。
- NumPy: 矩阵、向量、峰数组、过滤、排序、SVD 和误差统计。
- SciPy: Sobol 采样、最近邻查询和峰的一对一匹配。
- h5py: 保存和读取变长 Clean-Peak 数据。
- PyYAML: 读取统一的 Benchmark 参数文件。
- Matplotlib: 生成误差分布、距离分析和峰叠加图。

abTEM、ASE 和 scikit-image 用于后续 Dynamical 轨道，不参与本报告所述 Clean-Peak headline 指标的生成与计算。

6.2. py4DSTEM 在本项目中的作用

py4DSTEM 是本项目最核心的领域库。它在 Clean-Peak v3 中承担两项不同任务：

任务一：生成公开测试输入

已知 NCM811 晶体结构和隐藏真实取向 R_{gt} ，使用运动学衍射模型生成 一组理论衍射峰：

```
NCM811 Crystal + R_gt  
-> PointList(qx, qy, intensity)
```

经过中心束删除、半径过滤和强度归一化后，峰集合被写入 `public/clean_peaks.h5`。

任务二：实现 ACOM Baseline

已知 NCM811 晶体结构和公开峰集合，先建立 Orientation Plan，再通过稀疏相关匹配预测完整取向：

```
NCM811 Crystal  
+ Orientation Plan  
+ PointList(qx, qy, intensity)  
-> Orientation.matrix  
-> R_pred
```

因此，py4DSTEM 同时出现在数据生成端和 Baseline 端。

这也是当前结果被称为 matched-model self-consistency 的原因：Clean 输入和 ACOM 模板使用相同 CIF 与相同 py4DSTEM 运动学模型。该实验检验的是内部自洽性，不等同于真实实验数据泛化能力。

6.3. py4DSTEM 的四个核心对象

1. Crystal

Crystal 是 py4DSTEM 对参考晶体的内部表示。

它保存或派生以下信息：

- 晶格和原子结构；
- 倒易晶格；
- 结构因子；
- 电子束参数；
- Orientation Plan；
- 理论衍射模板。

本项目首先用 `pymatgen` 读取 CIF，再将 `Structure` 转换为 py4DSTEM 的 `Crystal`。

2. PointList

`PointList` 表示一组离散衍射峰，而不是完整像素图像。

本项目使用的每个峰包含：

```
qx
qy
intensity
```

其中 qx 、 qy 是探测器平面中的倒空间坐标，单位为 $\text{\AA}^{-1}$ ； $intensity$ 是归一化相对强度。

3. Orientation Plan

Orientation Plan 是针对已知参考晶体预先建立的候选取向模板库。

它由以下两层离散采样组成：

```
候选区轴方向
x
候选面内旋转角
```

Canonical 2° 配置生成：

```
1081 个区轴节点
180 个面内角节点
194580 个 normal seeds
389160 个含 mirror 的搜索 seeds
```

Orientation Plan 建立一次后，可以重复用于所有样本。

4. Orientation

Orientation 是 `match_single_pattern` 返回的匹配结果对象。

本项目主要读取：

- `orientation.matrix[0]`
- `orientation.corr[0]`
- `orientation.inds[0]`
- `orientation.mirror[0]`
- `orientation.angles[0]`

其中只有 `matrix[0]` 是最终 Benchmark 所需的取向预测；其余字段主要用于诊断。

6.4. 关键函数一：从 pymatgen 建立 Crystal

`Crystal.from_pymatgen_structure`

本项目调用：

```
structure = Structure.from_file(
    cif_path(config)
)

crystal = (
    py4DSTEM.process.diffraction.Crystal
```

```
.from_pymatgen_structure(
    structure=structure,
    conventional_standard_structure=False,
)
)
```

输入：

- structure: pymatgen 的 Structure 对象；
- conventional_standard_structure=False: 不要求 py4DSTEM 再将结构变换为常规标准晶胞。

处理过程：

1. 读取 pymatgen 中的晶格矩阵；
2. 读取原子种类、位置和占位信息；
3. 将结构转换为 py4DSTEM 可用于衍射计算的晶体对象；
4. 初始化后续倒易晶格和结构因子计算所需的数据。

输出：

返回一个 py4DSTEM.process.diffraction.Crystal 对象。

该对象此时已经知道晶体结构，但尚未完成电子衍射参数设置和结构因子计算。

6.5. 关键函数二：设置电子衍射条件

Crystal.setup_diffraction

本项目调用：

```
crystal.setup_diffraction(
    accelerating_voltage=300000.0,
)
```

输入：

- accelerating_voltage: 电子加速电压，单位为 V；
- 本项目固定为 300000 V，即 300 kV。

处理过程：

py4DSTEM 根据加速电压建立电子衍射计算所需的电子束参数，包括与电子波长和倒空间几何有关的内部量。

输出：

该函数主要更新 crystal 的内部状态。

本项目没有接收独立返回值，后续的结构因子计算、衍射模拟和 Orientation Plan 构建都会读取这些内部参数。

6.6. 关键函数三：计算结构因子

Crystal.calculate_structure_factors

本项目调用：

```
crystal.calculate_structure_factors(
    k_max=1.5,
    tol_structure_factor=1e-4,
)
```

输入：

- $k_{\max}=1.5$ ：考虑的最大倒空间半径，单位为 $\text{\AA}^{-1}$ ；
- $\text{tol_structure_factor}=1e-4$ ：删除结构因子过小的反射所使用的阈值。

处理过程：

1. 根据晶格生成给定 $k_{\max}$ 范围内的倒易晶格反射；
2. 根据 CIF 中的原子种类、位置和占位率计算结构因子；
3. 删除低于阈值的反射；
4. 将可用于衍射模拟的反射及其强度信息保存到 Crystal 中。

输出：

主要输出写入 crystal 内部状态。

后续的 generate_diffraction_pattern 和 orientation_plan 都基于这里计算出的倒易反射与结构因子。

6.7. 关键函数四：生成 Clean 衍射峰

Crystal.generate_diffraction_pattern

这是 Clean-Peak 数据生成阶段最重要的函数。

本项目调用：

```
point_list = crystal.generate_diffraction_pattern(
    orientation_matrix=R,
    sigma_excitation_error=0.02,
    tol_excitation_error_mult=3.0,
    tol_intensity=1e-4,
    k_max=1.5,
)
```

输入：

- orientation_matrix=R：当前样本的隐藏真实取向矩阵 R_{gt} ；
- sigma_excitation_error=0.02：激发误差权重宽度，单位为 $\text{\AA}^{-1}$ ；
- tol_excitation_error_mult=3.0：激发误差允许范围相对于宽度的倍数；
- tol_intensity=1e-4：删除弱峰的强度阈值；
- $k_{\max}=1.5$ ：最大输出倒空间半径，单位为 $\text{\AA}^{-1}$ 。

处理过程：

1. 读取之前计算好的倒易晶格反射和结构因子；
2. 根据 R_{gt} 将晶体倒空间反射转换到样品坐标系；
3. 计算各反射相对于电子束方向的激发误差；
4. 根据激发误差和结构因子计算运动学峰强度；
5. 删除超出激发范围、倒空间范围或强度阈值的峰；

6. 将保留反射投影为探测器平面坐标 qx 、 qy 。

输出：

返回一个 py4DSTEM PointList：

```
data = point_list.data  
  
qx = data["qx"]  
qy = data["qy"]  
intensity = data["intensity"]
```

在当前版本中，模拟器还可在内部结果中提供：

```
h  
k  
l
```

但 h, k, l 只写入诊断文件，不进入公开 Benchmark 输入。

`generate_diffraction_pattern` 接收的是完整的 3×3 取向矩阵，而不是只接收一个区轴。

因为同一区轴下，晶体仍然可以绕电子束方向发生面内旋转。只有完整取向矩阵才能同时确定区轴方向和探测器平面内的方向。

6.8. py4DSTEM 输出峰的后处理

py4DSTEM 返回 PointList 后，本项目还会执行自己的峰过滤逻辑。

```
qx = np.asarray(data["qx"], dtype=float)  
qy = np.asarray(data["qy"], dtype=float)  
intensity = np.asarray(  
    data["intensity"],  
    dtype=float,  
)  
  
radius = np.hypot(qx, qy)
```

保留条件为：

```
keep = (  
    np.isfinite(qx)  
    & np.isfinite(qy)  
    & np.isfinite(intensity)  
    & (radius >= 0.03)  
    & (radius <= 1.5 + 1e-8)  
    & (intensity > 0)  
)
```

随后执行最大值归一化：

```
intensity = intensity / intensity.max()
```

因此，公开峰不是未经处理的 py4DSTEM 原始输出，而是经过统一过滤、归一化和确定性排序后的结果。

6.9. 关键函数五：构造 ACOM 输入 PointList

py4DSTEM.PointList

公开 HDF5 文件中的三个数组需要重新包装为 py4DSTEM 的 PointList，才能传入 ACOM。

本项目调用：

```
dtype = np.dtype([
    ("qx", "f4"),
    ("qy", "f4"),
    ("intensity", "f4"),
])

data = np.empty(
    len(sample["qx"]),
    dtype=dtype,
)

data["qx"] = sample["qx"]
data["qy"] = sample["qy"]
data["intensity"] = sample["intensity"]

point_list = py4DSTEM.PointList(
    data=data,
    name=sample["sample_id"],
)
```

输入：

- 一个 NumPy structured array；
- 必须包含 qx、qy 和 intensity 三个字段；
- name 用于保存当前样本标识。

处理过程：

PointList 不会重新模拟衍射，而是将离散峰数组包装成 py4DSTEM 统一的数据对象，使 ACOM 可以读取字段名称、峰数量和峰值。

输出：

返回一个 PointList 对象，随后作为：

```
bragg_peaks=point_list
```

传入 match_single_pattern。

公开输入不包含 h,k,l，因此 ACOM Baseline 不能利用反射索引作为答案提示。

6.10. 关键函数六：建立 Orientation Plan

Crystal.orientation_plan

这是 ACOM 模板生成阶段最重要的函数。

本项目调用：

```
crystal.orientation_plan(
    zone_axis_range="auto",
    angle_step_zone_axis=2.0,
    angle_step_in_plane=2.0,
    accel_voltage=300000.0,
    corr_kernel_size=0.08,
    sigma_excitation_error=0.02,
    power_radial=1.0,
    power_intensity=0.25,
    power_intensity_experiment=0.25,
    tol_distance=0.01,
    CUDA=False,
    progress_bar=True,
)
```

输入一：取向搜索范围。

- zone_axis_range="auto": 根据晶体点群自动确定对称约化后的区轴搜索区域；
- angle_step_zone_axis=2.0: 区轴方向的近似角步长；
- angle_step_in_plane=2.0: 绕电子束的面内角离散步长。

输入二：相关模板参数。

- corr_kernel_size=0.08 Å⁻¹: 倒空间相关核的尺度；
- sigma_excitation_error=0.02 Å⁻¹: 理论模板的激发误差权重宽度；
- power_radial=1.0: 径向权重指数；
- power_intensity=0.25: 理论峰强度指数；
- power_intensity_experiment=0.25: 输入峰强度指数；
- tol_distance=0.01 Å⁻¹: 稀疏相关表示中的径向匹配容差。

输入三：计算设备。

- CUDA=False: 当前 canonical baseline 使用 CPU；
- progress_bar=True: 显示构建进度。

处理过程：

1. 根据 NCM811 的晶体对称性约化区轴搜索区域；
2. 在约化区域内生成离散区轴节点；
3. 为每个区轴构建理论衍射模板；
4. 将理论峰转换为适合稀疏相关的径向和角向表示；
5. 建立离散面内旋转角网格；
6. 将模板和取向矩阵保存在 crystal 内部。

输出：

该函数不直接返回某个样本的预测结果，而是更新 Crystal 中的 Orientation Plan 状态。

本项目之后读取的主要内部字段包括：

```
crystal.orientation_rotation_matrices
crystal.orientation_gamma
crystal.orientation_num_zones
crystal.orientation_in_plane_steps
```

Canonical 2°配置对应：

```
orientation_num_zones = 1081
orientation_in_plane_steps = 180
```

1081 和 180 不是手工逐个写入的模板数量。

人为固定的是 2° 区轴步长、 2° 面内步长和其他相关参数。py4DSTEM 根据这些参数及 NCM811 的晶体对称性自动生成 1081 个区轴节点和 180 个面内角节点。

6.11. 关键函数七：匹配单个衍射样本

`Crystal.match_single_pattern`

这是 ACOM 预测阶段最重要的函数。

本项目调用：

```
orientation = crystal.match_single_pattern(
    bragg_peaks=point_list,
    num_matches_return=1,
    min_number_peaks=3,
    inversion_symmetry=True,
    plot_polar=False,
    plot_corr=False,
    verbose=False,
)
```

输入：

- `bragg_peaks`: 当前样本的 `PointList(qx, qy, intensity)`;
- `num_matches_return=1`: 只返回相关分数最高的一个候选取向;
- `min_number_peaks=3`: 至少需要三个输入峰;
- `inversion_symmetry=True`: 同时搜索 `normal` 和 `mirror` 两个相关分支;
- `plot_polar=False`: 不在批量运行中绘制极坐标图;
- `plot_corr=False`: 不为每个样本绘制相关曲线;
- `verbose=False`: 关闭逐样本详细文本输出。

处理过程：

1. 将每个峰从 (qx, qy) 转换为极坐标 (q, γ) ;
2. 将输入峰组织成稀疏径向-角向表示;
3. 与 Orientation Plan 中的理论区轴模板计算相关;
4. 对角向维度搜索最佳面内旋转;
5. 当 `inversion_symmetry=True` 时, 同时比较 `normal` 和 `mirror` 分支;
6. 从全部候选中选择最高相关解;
7. 对最佳面内相关峰进行抛物线亚网格拟合;
8. 将最佳区轴和细化后的面内角组合成完整取向矩阵。

输出：

返回一个 py4DSTEM `Orientation` 对象：

```
orientation = crystal.match_single_pattern(...)
```

本项目再从中提取预测矩阵：

```
matrix_raw = np.asarray(
    orientation.matrix[0],
    dtype=float,
)

R_pred = nearest_rotation(matrix_raw)
```

其中 `nearest_rotation` 是本项目自己的 NumPy/SVD 后处理，用于消除浮点数造成的轻微非正交误差。

6.12. Orientation 返回字段

`orientation.matrix`

```
orientation.matrix[0]
```

输出最高相关候选的 3×3 完整取向矩阵。

它是 ACOM 的核心预测结果，在本项目中记为 `R_pred`。

最终提交文件只保存：

```
sample_id
orientation_matrix_sample_to_crystal
```

`orientation.corr`

```
orientation.corr[0]
```

输出最高候选的相关分数。

相关分数表示输入峰与 ACOM 理论模板在其相关函数下的匹配程度，但它不是取向角误差，也不能直接解释为准确率。

本项目将其保存为：

```
correlation_score
```

只用于诊断。

`orientation.inds`

```
orientation.inds[0, 0]
orientation.inds[0, 1]
```

分别给出：

- 选中的区轴 Plan 索引；

- 选中的离散面内角 Plan 索引。

这些索引用于追踪 ACOM 最初选中了哪个离散模板，但最终预测角可以经过亚网格拟合，因此预测结果不一定严格落在 2° 整数网格上。

orientation.mirror

```
orientation.mirror[0]
```

表示最高相关结果是否来自 ACOM 的 mirror 分支：

```
false -> normal branch
true  -> mirror branch
```

它是 ACOM 内部搜索分支的诊断字段，不等同于评价协议中的 Friedel-equivalent misorientation。

orientation.angles

```
orientation.angles[0]
```

输出 ACOM 表示该预测取向所使用的角参数，原始单位为弧度。

本项目转换为角度后写入报告：

```
euler_angles_deg = np.degrees(
    orientation.angles[0]
)
```

正式评价仍然直接使用 `orientation.matrix[0]`，而不是重新根据这些角度构造矩阵。

6.13. py4DSTEM 完整输入、过程与输出

Clean-Peak 生成端

输入:

```
pymatgen Structure
R_gt
300 kV
k_max = 1.5 Å-1
excitation-error 参数
```

过程:

```
Structure
-> Crystal
-> setup_diffraction
-> calculate_structure_factors
-> generate_diffraction_pattern
```

py4DSTEM 输出:

```
PointList
├─ qx
```

```
|— qy
|— intensity
└— h, k, l (仅诊断)
```

项目后处理:

- 删除中心束
- 删除非法值和弱峰
- 半径截断
- 强度最大值归一化
- 确定性排序

公开输出 :

- sample_id
- qx[]
- qy[]
- intensity[]

ACOM 预测端

输入:

- NCM811 Crystal
- Orientation Plan 参数
- PointList(qx, qy, intensity)

过程:

- orientation_plan
 - > 区轴模板
 - > 面内角网格
 - > sparse polar correlation
 - > normal / mirror 比较
 - > 面内角亚网格拟合
 - > match_single_pattern

py4DSTEM 输出:

- Orientation
 - |— matrix
 - |— corr
 - |— inds
 - |— mirror
 - └— angles

Benchmark 使用 :

- matrix[0] -> R_pred

Benchmark 自行评价 :

- R_pred
- vs.
- hidden R_gt
 - > strict error
 - > Friedel-equivalent error

6.14. pymatgen: 晶体结构与对称性

pymatgen 在本项目中负责读取和解释晶体结构。

读取 CIF:

```
from pymatgen.core import Structure

structure = Structure.from_file(
    cif_path(config)
)
```

Structure 提供:

- 晶格矩阵;
- 原子坐标;
- 元素信息;
- 占位率;
- 倒易晶格;
- 晶体对称分析所需的结构数据。

评价阶段还使用:

```
from pymatgen.symmetry.analyzer import (
    SpacegroupAnalyzer
)
```

获取点群操作后, 程序首先检查原始操作的 determinant, 只保留 $\det = +1$ 的 proper rotations。pymatgen 不负责 ACOM 相关匹配; 它为 py4DSTEM 和评价器提供 参考晶体结构与对称性信息。

6.15. NumPy: 矩阵和峰数组计算

NumPy 是整个项目的基础数值库, 主要用于:

- 将 JSON 和 HDF5 数据转换为数组;
- 构造和检查 3×3 取向矩阵;
- 计算点积、叉积、转置和行列式;
- 将四元数转换为旋转矩阵;
- 计算 $q = \sqrt{q_x^2 + q_y^2}$;
- 过滤、归一化和排序衍射峰;
- 计算均值、中位数和分位数;
- 通过 SVD 将近似矩阵投影到 $SO(3)$ 。

例如, ACOM 输出矩阵会经过:

```
U, _, Vt = np.linalg.svd(matrix)
R = U @ Vt

if np.linalg.det(R) < 0:
    U[:, -1] *= -1
    R = U @ Vt
```

该操作只修正微小数值误差, 不重新执行 ACOM 搜索。

6.16. SciPy: 采样、最近邻和一对一匹配

SciPy 在本项目中承担三个彼此独立的任务。

6.16.1. Sobol 低差异采样

```
from scipy.stats import qmc

points = qmc.Sobol(
    d=3,
    scramble=True,
    seed=20260728,
).random_base2(10)
```

该调用生成 $1024 = 2^{10}$ 个三维 Sobol 点，随后由项目自己的 Shoemake 函数映射到 $SO(3)$ 。

6.16.2. ACOM Plan 最近邻审计

```
from scipy.spatial import cKDTree
```

项目将全部离散搜索矩阵展平成九维向量，使用 `cKDTree` 查询真实取向到最近 ACOM seed 的距离。该距离只用于诊断，不参与主测试集筛选。

6.16.3. 探测器峰的一对一匹配

```
from scipy.optimize import linear_sum_assignment
```

坐标审计阶段使用 Hungarian assignment，在观测峰和预测峰之间建立一对一最小距离匹配，再删除超过指定 $\text{\AA}^{-1}$ 容差的峰对。

6.17. h5py：变长峰集合存储

不同取向产生的衍射峰数量不同，因此不能直接存为规则的 样本数 $\times$ 峰数 二维数组。

项目使用 h5py 将所有峰连接为长数组：

```
peaks/qx
peaks/qy
peaks/intensity
```

再使用：

```
peaks/offsets
```

记录每个样本在长数组中的开始和结束位置。

概念上：

```
sample 0 -> [offsets[0], offsets[1])
sample 1 -> [offsets[1], offsets[2])
sample 2 -> [offsets[2], offsets[3])
```

这种结构既支持每个样本不同的峰数量，也避免为缺失峰填充大量零值。

数据集还使用 gzip 压缩保存峰数组。

6.18. PyYAML：统一配置管理

项目通过：

```
yaml.safe_load(...)
```


读取:

```
config/benchmark.yaml
```

配置文件统一定义:

- 数据集标识与样本数量;
- Sobol seed;
- Clean 模拟参数;
- ACOM Orientation Plan 参数;
- 评价阈值;
- 文件路径;
- Dynamical 轨道预留参数。

因此脚本中重要实验参数不应重复硬编码, 而应优先从 `benchmark.yaml` 读取。

6.19. Matplotlib: 结果可视化

Matplotlib 不参与取向预测, 只负责生成报告图像, 包括:

- Strict 与 Friedel 误差分布;
- 4° 、 3° 、 2° 配置比较;
- 最近区轴节点距离与误差关系;
- 公开峰与预测峰叠加;
- 代表样本和严重错误样本可视化。

因此修改 Matplotlib 绘图样式不会改变 Benchmark 数值结果。

6.20. Dynamical 轨道使用的库

下列库已经出现在项目代码中, 但不参与当前 Clean-Peak headline:

- abTEM: 多层切片或相关电子显微模拟;
- ASE: 构造 abTEM 使用的原子结构;
- scikit-image: 通过 `peak_local_max` 提取图像峰;
- scipy.ndimage: 对模拟图像进行高斯平滑。

因此, 本报告中的 Clean-Peak ACOM 数值不能被描述为 abTEM dynamical simulation 的结果。

6.21. py4DSTEM 与项目自定义代码

由 py4DSTEM 完成

- Crystal 晶体对象构建;
- 电子衍射参数初始化;
- 结构因子计算;
- 运动学衍射峰生成;
- Orientation Plan 构建;
- 稀疏相关匹配;
- normal / mirror 分支搜索;
- 最佳取向及诊断字段输出。

由本项目代码完成

- Sobol–Shoemake 取向采样；
- R_sample_to_crystal 坐标约定；
- crystal/Friedel 等价重复检查；
- 峰过滤、归一化和 HDF5 存储；
- ACOM Plan 距离审计；
- 预测矩阵 SO(3) 数值修正；
- proper crystal symmetry 提取；
- Strict 与 Friedel–equivalent misorientation；
- Mean、Median、P90、P95 和 Accuracy 指标；
- SHA256、Git revision 和逐峰坐标审计。

因此，py4DSTEM 是本项目的模拟器和 ACOM Baseline 实现，但完整 Benchmark 并不完全由 py4DSTEM 自动生成。

样本采样、数据协议、隐藏答案、等价关系和最终评分均由 OR4D–NCM811 项目代码独立定义。

7. ACOM Baseline

7.1. Canonical Orientation Plan 参数

ACOM 的角步长是本次 Baseline 人为固定的超参数；区轴节点数、面内步数和搜索种子数由 py4DSTEM 根据晶体对称性与角步长自动得到。

参数	值	说明
zone_axis_range	auto	按点群自动约化搜索区轴区域
angle_step_zone_axis_deg	2°	Canonical 区轴近似步长
angle_step_in_plane_deg	2°	Canonical 面内离散步长
corr_kernel_size_Ainv	0.08 Å ⁻¹	相关核宽度
sigma_excitation_error_Ainv	0.02 Å ⁻¹	模板激发误差宽度
power_radial	1.0	径向权重指数
power_intensity_simulated	0.25	理论峰强度指数
power_intensity_experiment	0.25	输入峰强度指数
tol_distance_Ainv	0.01 Å ⁻¹	径向壳层归并容差
min_number_peaks	3	最少峰数量
inversion_symmetry	true	同时计算 normal 与 mirror
num_matches_return	1	仅返回最高相关解
cuda	false	CPU 执行

Canonical 2° Orientation Plan 规模：

项目	数量 / 时间
Zone–axis nodes	1081
In–plane steps	180
Normal discrete seeds	194,580

项目	数量 / 时间
Normal + mirror seeds	389,160
Plan 构建时间	0.097 s

计算关系：

$$1081 \times 180 = 194580$$

$$194580 \times 2 = 389160$$

7.2. ACOM 匹配流程

ACOM 推理链

```

公开 PointList(qx, qy, intensity)
→ 转换为稀疏极坐标 (q, gamma, intensity)
→ 对 1081 个区轴模板计算角向相关
→ FFT 搜索 180 个离散面内角
→ 同时比较 normal / mirror 分支
→ 对最佳面内相关峰做抛物线亚网格拟合
→ 输出 Orientation.matrix = R_pred

```

correlation_score、模板索引与 mirror_match 是 ACOM 诊断字段，不属于 Benchmark 强制提交字段。

7.3. 4° / 3° / 2°角分辨率扫描

所有扫描使用相同 CIF、取向 manifest、公开峰、ground truth、配置哈希与软件版本，只改变区轴和面内角步长。

Step	Mean	Median	P95	Acc@1°	Acc@2°	Acc@5°	Seeds incl. mirror	Throughput
4°	2.991°	1.625°	5.311°	20.8%	68.3%	94.6%	49,680	70.4/s
3°	2.581°	1.283°	5.069°	32.3%	84.7%	94.8%	119,040	32.9/s
2°	1.625°	0.977°	3.525°	52.1%	90.5%	96.7%	389,160	9.8/s

从 4°加密到 2°：搜索种子增加约 7.83 倍，匹配总时间由 15.3 s 增至 110.2 s，约慢 7.18 倍；同时中位误差由 1.625°降至 0.977°，Acc@2°由 68.3% 升至 90.5%。

8. 评价协议

8.1. Proper crystal point-group rotations

评价先检查 pymatgen 原始点群操作的 determinant，只保留 det = +1 的 proper rotations，再通过 SVD 处理微小数值误差。不能先把 improper operation 投影成旋转，否则会把镜面或反演错误地转换为无关 proper rotation。

8.2. 单个旋转矩阵的角度

两个合法取向的相对旋转：

$$\Delta R = R_{\text{pred}} R_{\text{target}}^T$$

旋转角：

$$\theta = \arccos\left(\frac{\text{tr}(\Delta R) - 1}{2}\right)$$

数值实现会先将余弦值裁剪到 $[-1, 1]$ 。

8.3. Strict misorientation

只考虑晶体 proper symmetry:

$$\Delta\theta_{\text{strict}} = \min_{S \in G} \text{angle}\left(R_{\text{pred}}(SR_{\text{gt}})^T\right)$$

它回答：预测完整三维取向在晶体旋转对称等价下与指定真值相差多少度。

8.4. Friedel-equivalent misorientation

Clean-Peak 理想运动学峰集可能无法区分探测器平面的 $q \leftrightarrow -q$ 中心对称等价。定义右作用于 sample frame 的 proper rotation:

$$F = \begin{pmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

主指标:

$$\Delta\theta_{\text{Friedel}} = \min_{S \in G, B \in \{I, F\}} \text{angle}\left(R_{\text{pred}}(SR_{\text{gt}}B)^T\right)$$

这里不是把实空间轴直接等同于 q_x, q_y 。右乘 F 会翻转 sample x、sample y 基轴；对同一晶体倒易矢量， $g_{\text{sample}} = R^T g_{\text{crystal}}$ 的前两项随之变号，因此探测器坐标映射为 $(q_x, q_y) \rightarrow (-q_x, -q_y)$ 。

ACOM 的 `mirror_match` 是算法内部的投影镜像搜索分支；Friedel 等价是 Benchmark 的观测可辨识评分关系。二者不能简单当作同一个概念。

8.5. 数据集汇总指标

对 headline 的每个主误差 e_i :

$$\text{Mean} = \frac{1}{N} \sum_{i=1}^N e_i$$

Median 是排序后的中间值；P90/P95 表示约 90%/95% 样本不超过该误差。

$$\text{Acc} \backslash @ \tau = \frac{\text{count}(e_i \leq \tau)}{N}$$

本报告给出 $\text{Acc}@1^\circ$ 、 $\text{Acc}@2^\circ$ 、 $\text{Acc}@5^\circ$ ，并统计:

Catastrophic $>5^\circ$ = $\#\{i : e_i > 5^\circ\}$
 Catastrophic $>10^\circ$ = $\#\{i : e_i > 10^\circ\}$

9. v3 实验结果

9.1. Headline core 总体结果

指标	Friedel 主指标	Strict 指标
样本数	1024	1024
Mean	1.625°	5.703°

指标	Friedel 主指标	Strict 指标
Median	0.977°	0.978°
P90	1.922°	1.979°
P95	3.525°	59.748°
Max	89.850°	96.620°
Acc@1°	52.1%	52.0%
Acc@2°	90.5%	90.0%
Acc@5°	96.7%	93.1%

Headline 结果摘要

```

Primary cohort           : headline_core, N = 1024
Median Friedel error     : 0.977°
P95 Friedel error        : 3.525°
Accuracy within 2°       : 90.5%
Accuracy within 5°       : 96.7%
Strict/Friedel disagreement : 6.45%
Friedel error > 5°       : 34 / 1024
Friedel error > 10°      : 12 / 1024
Maximum Friedel error     : 89.850°

```

9.2. 按 sample role 汇总

Role	N	Mean	Median	P95	Max	Acc@2°	Acc@5°
headline_core	1024	1.625°	0.977°	3.525°	89.850°	90.5%	96.7%
legacy_smoke	17	9.227°	0.667°	72.006°	72.006°	88.2%	88.2%
acom_grid_probe	40	14.996°	0.667°	72.006°	72.006°	80.0%	80.0%

legacy_smoke 与 acom_grid_probe 的平均值被 [001] 取向族的 72° 错误显著抬高，不能用它们的总体均值评价面内亚网格精度。

9.3. Grid probe 按区轴分解

Probe axis	N	Mean	Median	Max	Acc@5°
za_001	8	72.006°	72.006°	72.006°	0%
za_100	8	0.667°	0.667°	0.667°	100%
za_110	8	0.667°	0.667°	0.667°	100%
za_101	8	0.590°	0.590°	0.591°	100%
za_102	8	1.051°	1.051°	1.051°	100%

所有 8 个 [001] probe 均匹配到约 72° 错误取向；其余 4 个区轴的全部 32 个 probe 均低于 1.1°。这说明当前 probe 总表同时混合了“面内插值误差”和“区轴模式混淆”，应按区轴解释。

同样，legacy 中 clean_ori_000 ([001], 0°) 与 clean_ori_005 ([001], 6.1°) 均约 72.006°；其他 15 个 legacy 样本均低于 2°。

9.4. 按最近区轴节点距离分箱

距离区间	N	Mean	Median	P95	Max	Acc@2°	Acc@5°
$[0, 0.5)^\circ$	205	0.785°	0.398°	2.571°	6.634°	91.2%	98.5%
$[0.5, 1)^\circ$	648	1.757°	0.930°	3.412°	89.850°	90.9%	96.9%
$[1, 2)^\circ$	171	2.128°	1.225°	5.693°	70.131°	88.3%	93.6%

最近区轴节点距离与误差的 Pearson 相关系数仅 0.108；最近完整离散 seed 距离与误差的相关系数为 0.084。几何网格距离只能解释一部分误差，相关函数的模式选择和峰集可辨识性同样重要。

9.5. 按公开峰数量分箱

v3 设计文件要求报告峰数分箱，但自动生成的 Markdown 当前未输出该表。本 Typst 报告根据 `acom_clean_details.json` 补充固定分箱： <16 、 $16-19$ 、 $20-23$ 、 ≥ 24 。这些边界是报告级诊断，不属于正式评测契约。

峰数	N	Mean	Median	P95	Max	Acc@2°	Acc@5°
<16	26	0.786°	0.796°	1.358°	1.651°	100%	100%
$16-19$	427	1.173°	0.948°	2.095°	13.121°	93.7%	98.1%
$20-23$	437	1.697°	0.945°	2.124°	89.850°	93.8%	97.3%
≥ 24	134	2.990°	1.272°	6.607°	71.329°	67.9%	89.6%

峰数较多组误差反而更高，不能解释为“更多峰导致更差”。峰数与区轴、反射几何和取向难度共同变化，该表只描述相关性，不证明因果关系。

9.6. 运行性能

项目	Canonical 2°结果
Orientation Plan 构建	0.0975 s
1081 样本匹配总时间	110.206 s
单样本平均	0.1019 s
P50	0.0975 s
P90	0.1228 s
P99	0.1580 s
吞吐量	9.8 samples/s

10. 坐标与峰级审计

10.1. 全局坐标一致性

`scripts/10_trace_clean_coordinates.py` 对 1081 个样本逐反射记录：

A：实空间直接晶格矩阵
 a^* , b^* , c^* ：晶体学倒易基底
 $g_crystal$ ：由 HKL 得到的晶体笛卡尔倒易矢量
 g_sample ：R.T @ $g_crystal$
 qx , qy , qz ：样品坐标中的倒易分量
ACOM 预测取向重新生成的峰
探测器 q 平面一对一峰匹配

诊断量	结果
标准 HKL→q 恒等式最大残差	$8.074 \times 10^{-8} \text{ \AA}^{-1}$
全部样本 ACOM 峰中位观测匹配率	88.24%
全部样本 ACOM 峰平均观测匹配率	86.69%
Headline 中位观测匹配率	87.50%
Headline 中位 q-RMSE	$0.0006 \text{ \AA}^{-1}$
Headline 中位强度 MAE	0.0547
Headline 原始 HKL 相同率中位数	0.0%
计入 $(h, k, l) \leftrightarrow (-h, -k, -l)$ 后	15.9%

原始 HKL 标签会因 crystal symmetry 与 Friedel 等价发生改变，因此 HKL 相同率只作诊断；主判断依据是 detector-plane q 匹配与 symmetry/Friedel-aware 误取向。

10.2. 代表样本

sample	误差	observed/pred/ matched	match	q-RMSE	raw HKL
clean_core_0970	0.022°	21/21/21	100.0%	0.0001	0.000
clean_core_0530	0.977°	22/21/19	86.4%	0.0005	1.000
clean_core_0198	3.522°	19/17/15	78.9%	0.0018	0.133
clean_core_0037	89.850°	23/17/17	73.9%	0.0071	0.294

即使灾难性取向错误的 q-RMSE 仍可能很小，说明有限峰集合可以存在高度相似的错误模式；仅看峰坐标重合率不能替代完整取向评价。

10.3. Headline 最严重错误样本

sample	误差	corr	obs/pred/ matched	q-RMSE	mirror
clean_core_0037	89.850°	2.8631	23/17/17	0.0071	false
clean_core_0211	89.848°	2.8577	22/17/17	0.0066	false
clean_core_0722	71.329°	2.8864	25/20/12	0.0066	false
clean_core_0347	70.131°	2.7978	28/20/15	0.0080	true
clean_core_0862	69.839°	2.9680	21/21/20	0.0063	true
clean_core_0694	13.121°	2.6319	17/15/15	0.0173	false
clean_core_0671	11.690°	2.6753	22/17/17	0.0009	false
clean_core_0982	11.460°	2.5662	19/17/16	0.0016	false
clean_core_0416	11.329°	2.7334	22/17/17	0.0006	false
clean_core_0018	11.180°	2.6794	18/20/15	0.0005	false

11. 可视化结果

11.1. 误差分布




图 1 Headline core 的 Strict 与 Friedel-equivalent 误差分布、ECDF 与阈值统计。

Friedel 主指标显著降低了一部分由 Clean 可观测等价造成的严格误差，但仍保留 5 个大于 60° 的 headline 灾难性模式。

11.2. 区轴网格距离与误差




图 2 最近区轴节点距离、最近离散 seed 距离与 Friedel 主误差的关系。

相关系数较弱，说明加密网格能改善总体精度，但异常错误不能只用“真实取向离最近模板多远”解释。

11.3. 输入峰与预测峰叠加




图 3 固定数量代表样本的输入峰与 ACOM 预测取向重新模拟峰叠加。

峰匹配在 detector q 平面中进行一对一最小距离分配，并以 $0.08 \text{ \AA}^{-1}$ 截断。每个样本的强度分别归一化，因此不能跨样本比较绝对亮度。

12. 可复现性

12.1. 软件与系统

项目	值
Source git revision	efb0672e3766e1ca48883028bc0b6f7b666b85bc
Python	3.11.15
NumPy	1.26.4
py4DSTEM	0.14.18
pymatgen	2024.7.18
h5py	3.16.0
Conda 环境	or4d-clean
Canonical device	CPU, cuda=false

12.2. SHA256

对象	SHA256
cif	60f28f9d4ace01baeab707d22c8de267ce0c7759c3574598fb1abe84e4fef94f
config	0b4dec56efef03c800195244d29e8b8e3c9154499c5739618f341c6c86cb18ed
ground_truth	e21741a3afa5af4a4e7f55b6bad04c44e1925ee07d8ac67d4692d24460ae9247
orientation_manifest	8cd01fd71503f434137390ca05050093ae324bd7f9f0b2f196372ec6edf5f88b
public_peaks	8cd3d73f8d5c818096b740af84a43ee5be0c61ca13fa139095a9d41ceb034685

12.3. 工程目录

```
OR4D-NCM811-smoke-v0/
├── config/benchmark.yaml
├── data/structure/NCM811_113035.cif
├── docs/CLEAN_BENCHMARK_V3.md
├── src/
│   ├── or4d_common.py
│   ├── clean_sampling.py
│   └── coordinate_trace.py
├── scripts/
│   ├── 01_generate_orientations.py
│   ├── 02_generate_clean.py
│   ├── 04_validate_dataset.py
│   ├── 05_make_submission_template.py
│   ├── 06_evaluate_submission.py
│   ├── 07_run_acom_baseline.py
│   ├── 08_visualize_acom_results.py
│   ├── 09_write_acom_report.py
│   ├── 10_trace_clean_coordinates.py
│   ├── 11_run_acom_sweep.py
│   └── 12_write_coordinate_visualization.py
├── tests/
│   ├── test_clean_sampling.py
│   ├── test_coordinate_trace.py
│   └── test_evaluation_contract.py
├── public/clean_peaks.h5
├── private/clean_ground_truth.jsonl
├── reports/
└── submissions/
```

12.4. 完整运行

```
conda activate or4d-clean
cd /Users/xie/code/OR4D-NCM811-smoke-v0
./run_clean_acom.sh
```

主要步骤：

```
python scripts/01_generate_orientations.py
python scripts/02_generate_clean.py
python scripts/04_validate_dataset.py
python scripts/11_run_acom_sweep.py
python scripts/08_visualize_acom_results.py
python scripts/09_write_acom_report.py
python scripts/10_trace_clean_coordinates.py --all
python scripts/12_write_coordinate_visualization.py
```

13. 结论

v3 当前定位

```
Input      : variable-length {qx, qy, intensity}
Ground truth: 3x3 sample-to-crystal orientation matrix
Headline   : 1024 ACOM-independent Sobol-SO(3) samples
Baseline   : py4DSTEM ACOM 0.14.18, canonical 2° / 2°
Primary    : proper-symmetry + Friedel-aware misorientation
Result     : Median 0.977°, Acc@2° 90.5%, Acc@5° 96.7%
Boundary   : matched-model Clean self-consistency, not real-data generalization
```

v3 已经建立了从取向采样、Clean 峰生成、统一 I/O、ACOM Baseline、symmetry/Friedel 评价、角分辨率扫描、坐标追踪到可复现哈希的完整闭环。它可以作为后续算法开发的规范 Clean 上限基准。

但当前 [001] 取向族在 $k_{\max} = 1.5 \text{ \AA}^{-1}$ 下出现稳定约 72° 错误，是 v3 最重要的科学问题。下一版本应优先解释这一模式，并建设 clean_crossgen、dynamical 与真实数据轨道，而不是只继续扩大样本数或加密 ACOM 网格。

14. 附录：术语

English	中文
Benchmark	评测基准
Crystal orientation	晶体取向
Orientation matrix	取向矩阵
Zone axis	区轴
In-plane rotation	面内旋转
SO(3)	所有合法三维 proper rotations 的集合
Low-discrepancy sampling	低差异采样
Scrambled Sobol sequence	加扰 Sobol 低差异序列
Shoemake mapping	均匀四元数旋转映射
Reciprocal space	倒空间
Scattering vector	散射矢量
Kinematical diffraction	运动学衍射
Orientation Plan	取向模板库
Sparse correlation	稀疏相关
Ground truth	隐藏真值 / 标准答案
Misorientation	取向差角
Proper rotation	行列式为 +1 的正旋转
Mirror branch	ACOM 镜像搜索分支
Friedel-equivalent	弗里德尔可观测等价
Sub-grid refinement	亚网格细化
Matched-model	生成器与 Baseline 使用相同模型
Cross-generator	独立生成器交叉测试

English	中文
ECDF	经验累积分布函数
HDF5	层次化数据格式
JSONL	每行一个 JSON 对象